Tedu.cn
达内教育

Linux 大数据

NSD HADOOP DAY03

内容

上午	09:00 ~ 09:30	课程回顾
	09:30 ~ 10:20	常用组件
	10:30 ~ 11:20	
	11:30 ~ 12:00	
下午	14:00 ~ 14:50	Hadoop高可用
	15:00 ~ 15:50	
	16:10 ~ 17:00	
	17:10 ~ 18:00	总结和答疑

大数据

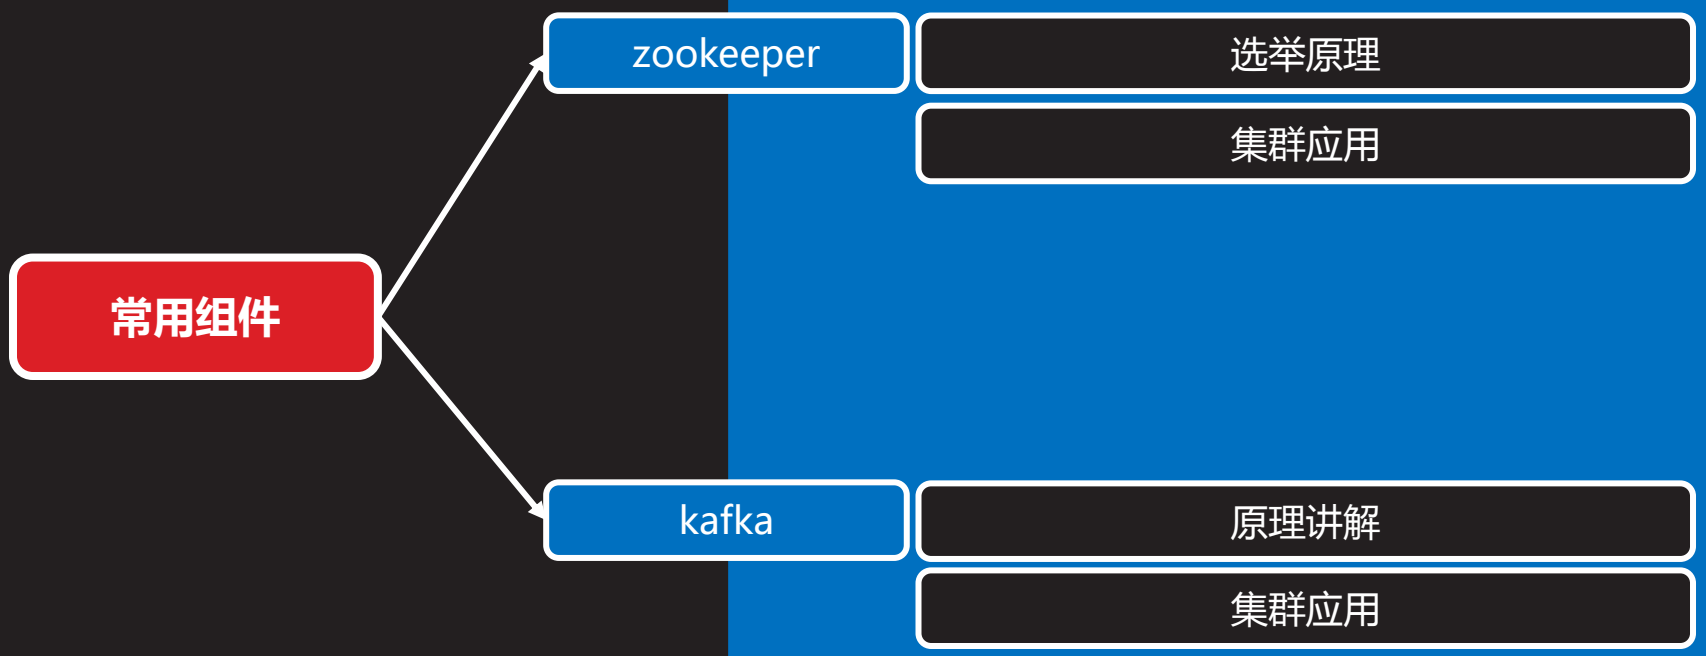

zookeeper

zookeeper

- zookeeper 是什么？
  - ZooKeeper是一个分布式的，开放源码的分布式应用程序协调服务
- ZooKeeper能干什么哪？
  - ZooKeeper是用来保证数据在集群间的事务性一致

zookeeper

- zookeeper 应用场景
  - 集群分布式锁
  - 集群统一命名服务
  - 分布式协调服务
  - ……

知识讲解

zookeeper

- zookeeper 角色与特性
  - Leader：
  - 接受所有Follower的提案请求并统一协调发起提案的投票，负责与所有的Follower进行内部的数据交换
  - Follower：
  - 直接为客户端服务并参与提案的投票，同时与Leader进行数据交换
  - Observer：
  - 直接为客户端服务但并不参与提案的投票，同时也与Leader进行数据交换

知识讲解

zookeeper

- zookeeper 角色与选举
  - 服务在启动的时候是没有角色的（LOOKING）
  - 角色是通过选举产生的
  - 选举产生一个 leader，剩下的是 follower

  - 选举 leader 原则：
  - 集群中超过半数机器投票选择leader.
  - 假如集群中拥有n台服务器，那么leader必须得到n/2+1台服务器投票

知识讲解

zookeeper

- zookeeper 角色与选举
  - 如果 leader 死亡，从新选举 leader
  - 如果死亡的机器数量达到一半，集群挂起
  - 如果无法得到足够的投票数量，就重新发起投票，如果参与投票的机器不足 n/2+1 集群停止工作
  - 如果 follower 死亡过多，剩余机器不足 n/2+1 集群也会停止工作
  - observer 不计算在投票总设备数量里面

知识讲解

zookeeper

- zookeeper 可伸缩扩展性原理与设计
  - leader 所有写相关操作
  - follower 读操作与响应leader提议
  - 在Observer出现以前，ZooKeeper的伸缩性由Follower来实现，我们可以通过添加Follower节点的数量来保证ZooKeeper服务的读性能。但是随着Follower节点数量的增加，ZooKeeper服务的写性能受到了影响。为什么会出现这种情况？在此，我们需要首先了解一下这个"ZK服务"是如何工作的。

知识讲解

zookeeper

- zookeeper 可伸缩扩展性原理与设计
  - 客户端提交一个请求，若是读请求，则由每台Server的本地副本数据库直接响应。若是写请求，需要通过一致性协议（Zab）来处理
  - Zab协议规定：来自Client的所有写请求，都要转发给ZK服务中唯一的Leader，由Leader根据该请求发起一个Proposal。然后，其他的Server对该Proposal进行Vote。之后，Leader对Vote进行收集，当Vote数量过半时Leader会向所有的Server发送一个通知消息。最后，当Client所连接的Server收到该消息时，会把该操作更新到内存中并对Client的写请求做出回应

知识讲解

zookeeper

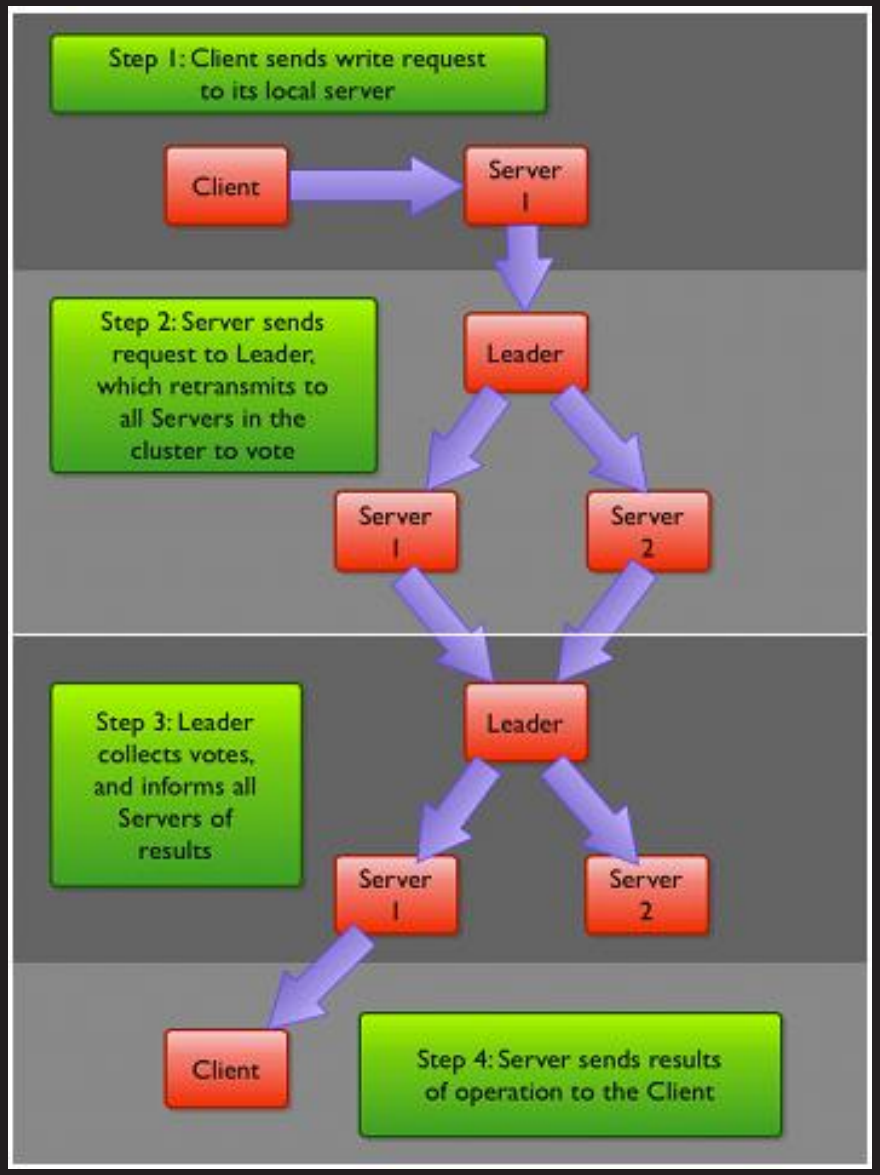

知识讲解

zookeeper

- 续上页
  - ZooKeeper 服务器在上述协议中实际扮演了两个职能。它们一方面从客户端接受连接与操作请求，另一方面对操作结果进行投票。这两个职能在 ZooKeeper集群扩展的时候彼此制约
  - 从Zab协议对写请求的处理过程中我们可以发现，增加follower的数量，则增加了对协议中投票过程的压力。因为Leader节点必须等待集群中过半Server响应投票，于是节点的增加使得部分计算机运行较慢，从而拖慢整个投票过程的可能性也随之提高，随着集群变大，写操作也会随之下降

知识讲解

zookeeper

- 续上页
  - 所以，我们不得不，在增加Client数量的期望和我们希望保持较好吞吐性能的期望间进行权衡。要打破这一耦合关系，我们引入了不参与投票的服务器，称为Observer。 Observer可以接受客户端的连接，并将写请求转发给Leader节点。但是，Leader节点不会要求 Observer参加投票。相反，Observer不参与投票过程，仅仅在上述第3步那样，和其他服务节点一起得到投票结果

知识讲解

zookeeper

- 续上页
  - Observer的扩展，给 ZooKeeper 的可伸缩性带来了全新的景象。我们现在可以加入很多 Observer 节点，而无须担心严重影响写吞吐量。但他并非是无懈可击的，因为协议中的通知阶段，仍然与服务器的数量呈线性关系。但是，这里的串行开销非常低。因此，我们可以认为在通知服务器阶段的开销不会成为瓶颈
  - Observer提升读性能的可伸缩性
  - Observer提供了广域网能力

知识讲解

zookeeper

- ZK 集群的安装配置
  - 配置文件改名 zoo.cfg

    mv zoo_sample.cfg zoo.cfg
  - zoo.cfg 最后添加
  - server.1=node1:2888:3888
  - server.2=node2:2888:3888
  - server.3=node3:2888:3888
  - server.4=hann1:2888:3888:observer

知识讲解

zookeeper

知识讲解

- zoo.cfg 集群的安装配置
  - 创建 datadir 指定的目录
  - mkdir /tmp/zookeeper
  - 在目录下创建 id 对应的主机名的 myid 文件
- 关于myid文件：
  - myid文件中只有一个数字
  - 注意，请确保每个server的myid文件中id数字不同
  - server.id 中的 id 与 myid 中的 id 必须一致
  - id的范围是1~255

zookeeper

- ZK 集群的安装配置
  - 启动集群，查看验证
  - 在所有集群节点执行
  - /usr/local/zk/bin/zkServer.sh start
  - 查看角色
  - /usr/local/zk/bin/zkServer.sh status
  - or
  - { echo 'stat';yes; }|telnet 192.168.4.10 2181
  - Zookeeper 管理文档

知识讲解

zookeeper

- Zookeeper 安装
  - 搭建 zookeeper 集群
  - 查看各服务器的角色

- 高可用实验
  - 停止 leader
  - 查看各服务器的角色

课堂练习

kafka 集群

kafka集群

- kafka是什么?
  - Kafka是由LinkedIn开发的一个分布式的消息系统
  - kafka是使用Scala编写
  - kafka是一种消息中间件
- 为什么要使用 kafka
  - 解耦、冗余、提高扩展性、缓冲
  - 保证顺序，灵活，削峰填谷
  - 异步通信

知识讲解

kafka集群

- kafka 角色与集群结构
  - producer：生产者，负责发布消息
  - consumer：消费者，负责读取处理消息
  - topic：消息的类别
  - Parition：每个Topic包含一个或多个Partition.
  - Broker：Kafka集群包含一个或多个服务器

  - Kafka通过Zookeeper管理集群配置，选举leader

kafka集群

- kafka 角色与集群结构

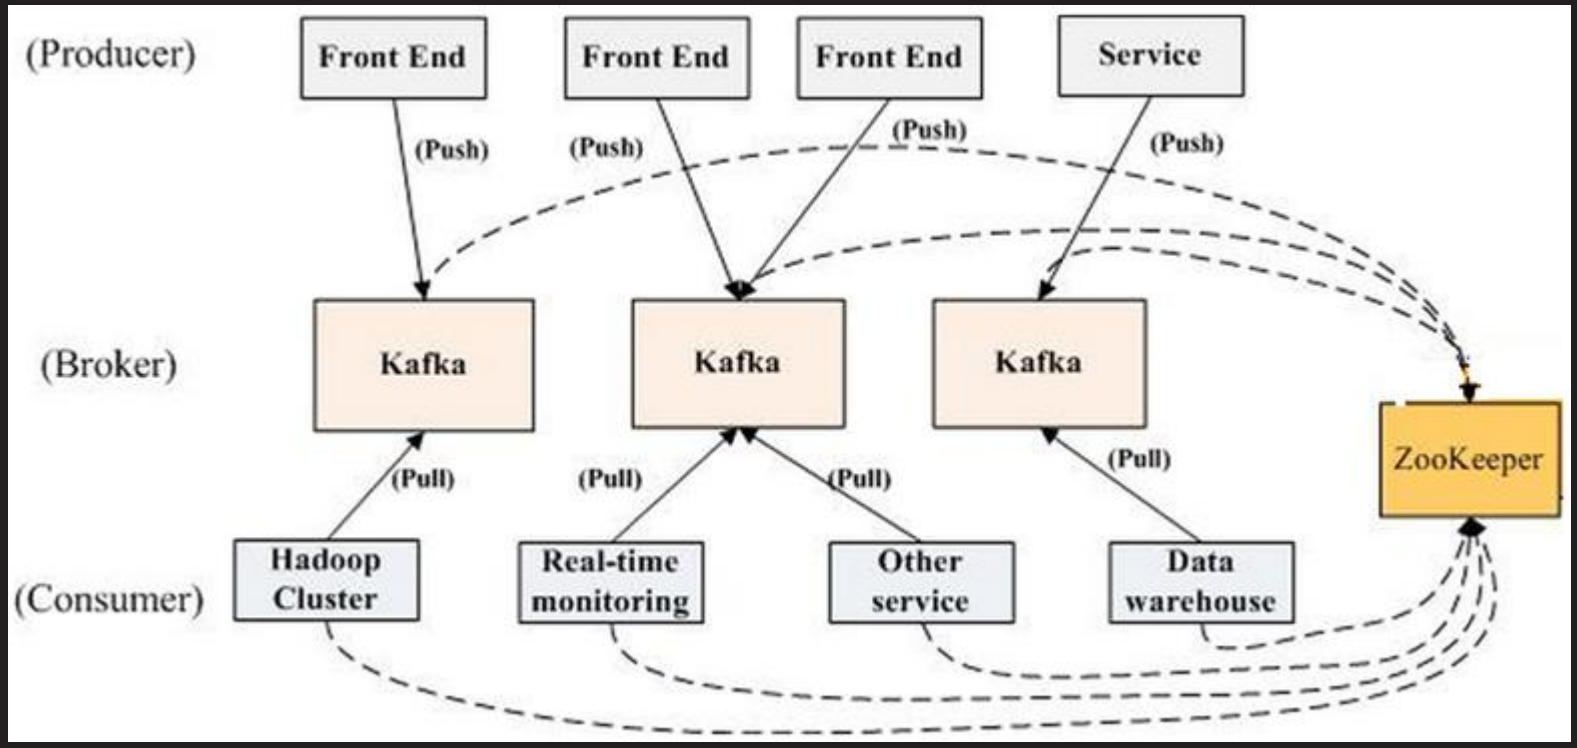

kafka集群

- kafka 集群的安装配置
  - kafka集群的安装配置是依赖 zookeeper的，搭建 kafka 集群之前，首先请创建好一个可用 zookeeper 集群
  - 安装 openjdk 运行环境
  - 分发 kafka 拷贝到所有集群主机
  - 修改配置文件
  - 启动与验证

知识讲解

kafka集群

- kafka 集群的安装配置
- server.properties
  - broker.id
  - 每台服务器的broker.id都不能相同
  - zookeeper.connect
  - zookeeper 集群地址，不用都列出，写一部分即可

知识讲解

kafka集群

- kafka 集群的安装配置
  - 在所有主机启动服务

    ./bin/kafka-server-start.sh -daemon config/server.properties
  - 验证
  - jps 命令应该能看到 kafka 模块
  - netstat 应该能看到 9092 在监听

知识讲解

kafka集群

- 集群验证与消息发布
  - 创建一个 topic

    ./bin/kafka-topics.sh --create --partitions 2 --replication-factor 2 --zookeeper node3:2181 --topic mymsg
  - 生产者

    ./bin/kafka-console-producer.sh --broker-list master:9092,node1:9092 --topic mymsg
  - 消费者

    ./bin/kafka-console-consumer.sh --bootstrap-server node2:9092,node3:9092 --topic mymsg

知识讲解

kafka集群实验

- 利用 zookeeper 搭建一个 kafka 集群

课堂练习

- 创建一个 topic
- 模拟生产者发布消息
- 模拟消费者接收消息

大数据

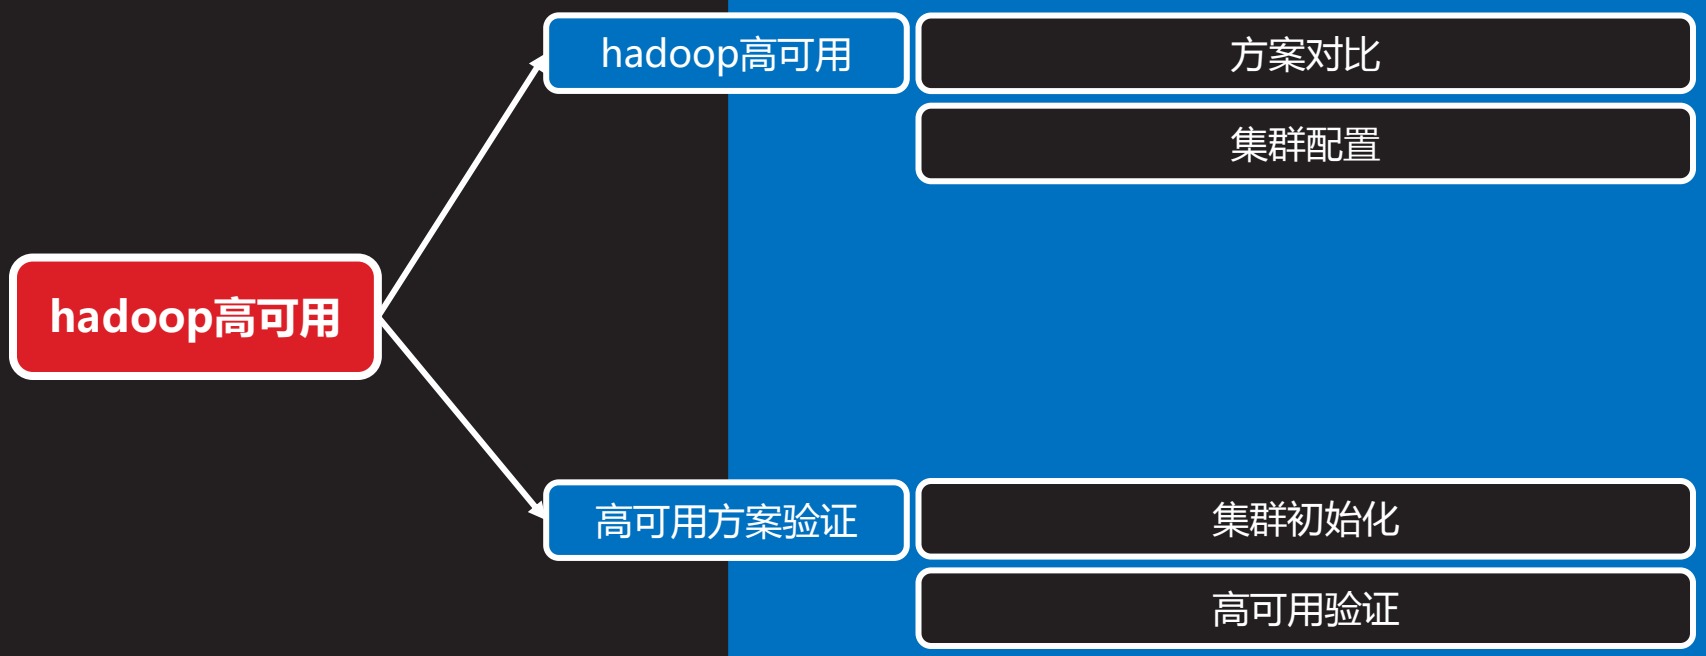

Hadoop 高可用

NameNode 高可用

- 为什么 NameNode 需要高可用
  - NameNode 是 HDFS 的核心配置，HDFS 又是 Hadoop 的核心组件，NameNode 在 Hadoop 集群中至关重要，NameNode机器宕机，将导致集群不可用，如果NameNode 数据丢失将导致整个集群的数据丢失，而 NameNode 的数据的更新又比较频繁，实现 NameNode 高可用势在必行

知识讲解

NameNode 高可用

- 为什么 NameNode 需要高可用
  - 官方提供了两种解决方案
  - HDFS with NFS
  - HDFS with QJM
  - 两种翻案异同

NFS	QJM
NN	NN
ZK	ZK
ZKFailoverController	ZKFailoverController
NFS	JournalNode

知识讲解

NameNode 高可用

- HA 方案对比
  - 都能实现热备
  - 都是一个active NN 和一个 standby NN
  - 都使用Zookeeper 和 ZKFC 来实现自动失效恢复
  - 失效切换都使用 fencing 配置的方法来 active NN
  - NFS 数据数据共享变更方案把数据存储在共享存储里面，我们还需要考虑 NFS 的高可用设计
  - QJM 不需要共享存储，但需要让每一个 DN 都知道两个 NN 的位置，并把块信息和心跳包发送给active和standby这两个 NN

知识讲解

NameNode 高可用

- NameNode 高可用方案 (QJM)
  - 为了解决 NameNode 单点故障问题，Hadoop 给出了 HDFS 的高可用HA方案：HDFS 通常由两个NameNode组成，一个处于 active 状态，另一个处于 standby 状态。Active NameNode对外提供服务，比如处理来自客户端的 RPC 请求，而 Standby NameNode 则不对外提供服务，仅同步 Active NameNode 的状态，以便能够在它失败时进行切换。

知识讲解

NameNode 高可用

- NameNode 高可用架构
  - 一个典型的HA集群，NameNode会被配置在两台独立的机器上，在任何时间上，一个NameNode处于活动状态，而另一个NameNode处于备份状态，活动状态的NameNode会响应集群中所有的客户端，备份状态的NameNode只是作为一个副本，保证在必要的时候提供一个快速的转移。

知识讲解

NameNode 高可用

- NameNode 高可用架构 续.....
  - 为了让Standby Node与Active Node保持同步，这两个Node都与一组称为JNS的互相独立的进程保持通信(Journal Nodes)。当Active Node上更新了namespace，它将记录修改日志发送给JNS的多数派。Standby noes将会从JNS中读取这些edits，并持续关注它们对日志的变更。Standby Node将日志变更应用在自己的namespace中，当failover发生时，Standby将会在提升自己为Active之前，确保能够从JNS中读取所有的edits，即在failover发生之前Standy持有的namespace应该与Active保持完全同步。

知识讲解

NameNode 高可用

- NameNode 高可用架构 续……
  - NameNode 更新是很频繁的，为了的保持主备数据的一致性，为了支持快速failover，Standby node持有集群中blocks的最新位置是非常必要的。为了达到这一目的，DataNodes上需要同时配置这两个Namenode的地址，同时和它们都建立心跳链接，并把block位置发送给它们

知识讲解

NameNode 高可用

- NameNode 高可用架构 续……
  - 还有一点非常重要，任何时刻，只能有一个Active NameNode，否则将会导致集群操作的混乱，那么两个NameNode将会分别有两种不同的数据状态，可能会导致数据丢失，或者状态异常，这种情况通常称为“split-brain”（脑裂，三节点通讯阻断，即集群中不同的Datanode 看到了不同的Active NameNodes）。对于JNS而言，任何时候只允许一个NameNode作为writer；在failover期间，原来的Standby Node将会接管Active的所有职能，并负责向JNS写入日志记录，这中机制阻止了其他NameNode基于处于Active状态的问题。

知识讲解

NameNode 高可用

- NameNode 高可用架构 续.....

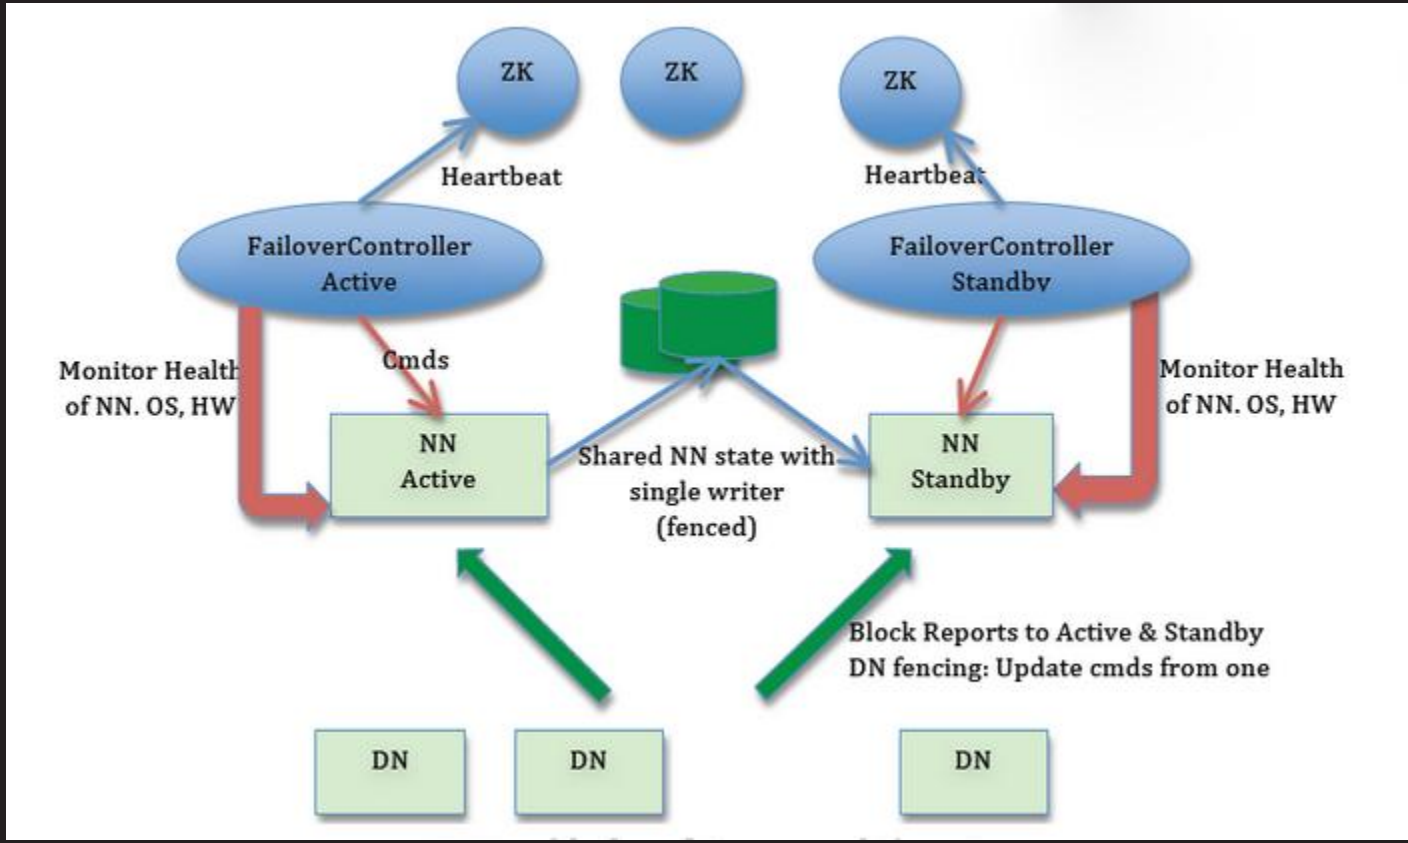

知识讲解

NameNode 高可用

- 系统规划

主机	角色	软件
192.168.4.10	NameNode1	Hadoop
192.168.4.20	NameNode2	Hadoop
Node1	DataNode journalNode Zookeeper	HDFS Zookeeper
Node2	DataNode journalNode Zookeeper	HDFS Zookeeper
Node3	DataNode journalNode Zookeeper	HDFS Zookeeper

知识讲解

NameNode 高可用

- core-site.xml

```
<property>
  <name>fs.defaultFS</name>
  <value>hdfs://mycluster</value>
</property>
<property>
  <name>hadoop.tmp.dir</name>
  <value>/var/hadoop</value>
</property>
<property>
  <name>ha.zookeeper.quorum</name>
  <value>node1:2181,node2:2181,node3:2181</value>
</property>
```

知识讲解

NameNode 高可用

知识讲解

- hdfs-site.xml

```
<property>
  <name>dfs.replication</name>
  <value>2</value>
</property>
```

  - secondarynamenode 在高可用里面没有用途，这里把他关闭
  - namenode 在后面定义

NameNode 高可用

- hdfs-site.xml　续 ……
  - <!-- 指定hdfs的nameservices名称为mycluster -->

```
<property>
    <name>dfs.nameservices</name>
    <value>mycluster</value>
</property>
```

  - 指定集群的两个 NaneNode 的名称分别为nn1,nn2

```
<property>
    <name>dfs.ha.namenodes.mycluster</name>
    <value>nn1,nn2</value>
</property>
```

知识讲解

NameNode 高可用

- hdfs-site.xml　续 ……
  - 配置nn1,nn2的rpc通信端口

```
<property>
    <name>dfs.namenode.rpc-address.mycluster.nn1</name>
    <value>node1:8020</value>
</property>
<property>
    <name>dfs.namenode.rpc-address.mycluster.nn2</name>
    <value>node2:8020</value>
</property>
```

知识讲解

NameNode 高可用

- hdfs-site.xml　续 ……
  - 配置nn1,nn2的http通信端口

```
<property>
    <name>dfs.namenode.http-address.mycluster.nn1</name>
    <value>node1:50070</value>
</property>
<property>
    <name>dfs.namenode.http-address.mycluster.nn2</name>
    <value>node2:50070</value>
</property>
```

知识讲解

NameNode 高可用

- hdfs-site.xml　续 ……
  - 指定namenode元数据存储在journalnode中的路径

```
<property>
    <name>dfs.namenode.shared.edits.dir</name>

<value>qjournal://node1:8485;node2:8485;node3:8485/my
cluster</value>
</property>
```

  - 指定journalnode日志文件存储的路径

```
<property>
    <name>dfs.journalnode.edits.dir</name>
    <value>/var/hadoop/journal</value>
</property>
```

知识讲解

NameNode 高可用

- hdfs-site.xml　续 ……
  - 指定HDFS客户端连接active namenode的java类

```
<property>

<name>dfs.client.failover.proxy.provider.mycluster</name>

<value>org.apache.hadoop.hdfs.server.namenode.ha.ConfiguredFailoverProxyProvider</value>
</property>
```

知识讲解

NameNode 高可用

- hdfs-site.xml　续 ……
  - 配置隔离机制为 ssh

```
<property>
    <name>dfs.ha.fencing.methods</name>
    <value>sshfence</value>
</property>
```

  - 指定秘钥的位置

```
<property>
    <name>dfs.ha.fencing.ssh.private-key-files</name>
    <value>/root/.ssh/id_rsa</value>
</property>
```

知识讲解

NameNode 高可用

- hdfs-site.xml　续 ……
  - 开启自动故障转移

```
<property>
    <name>dfs.ha.automatic-failover.enabled</name>
    <value>true</value>
</property>
```

知识讲解

Yarn 高可用

- ResourceManager 高可用
  - RM 的高可用原理与 NN 是一样的，需要依赖 ZK 来实现，这里就不重复了，只给出配置文件的关键部分，感兴趣的同学可以自己学习和测试
  - yarn.resourcemanager.hostname
  - 同理因为使用集群模式，该选项应该关闭

知识讲解

Yarn 高可用

- yarn-site.xml 配置

```
<property>
        <name>yarn.resourcemanager.ha.enabled</name>
        <value>true</value>
</property>

<property>
        <name>yarn.resourcemanager.ha.rm-ids</name>
        <value>rm1,rm2</value>
</property>
```

知识讲解

Yarn 高可用

- yarn-site.xml 配置

```
<property>

<name>yarn.resourcemanager.recovery.enabled</name>
    <value>true</value>
</property>

<property>
    <name>yarn.resourcemanager.store.class</name>

<value>org.apache.hadoop.yarn.server.resourcemanager.recovery.ZKRMStateStore</value>
</property>
```

知识讲解

Yarn 高可用

- yarn-site.xml 配置

```
<property>
        <name>yarn.resourcemanager.zk-address</name>
        <value>node1:2181,node2:2181,node3:2181</value>
</property>

<property>
        <name>yarn.resourcemanager.cluster-id</name>
        <value>yarn-ha</value>
</property>
```

知识讲解

Yarn 高可用

- yarn-site.xml 续 ……

```
<property>

<name>yarn.resourcemanager.hostname.rm1</name>
    <value>node1</value>
</property>

<property>

<name>yarn.resourcemanager.hostname.rm2</name>
    <value>node2</value>
</property>
```

知识讲解

Tedu.cn
达内教育

高可用验证

集群初始化

- 初始化
  - ALL: 所有机器
  - nodeX： node1　node2　node3

  - ALL: 同步配置到所有集群机器
  - NN1: 初始化ZK集群　./bin/hdfs zkfc -formatZK
  - nodeX: 启动 journalnode 服务

    ./sbin/hadoop-daemon.sh start journalnode

知识讲解

集群初始化

- 初始化
  - NN1: 格式化

    ./bin/hdfs namenode -format
  - NN2: 数据同步到本地 /var/hadoop/dfs

    rsync -aSH nn01:/var/hadoop/dfs /var/hadoop/
  - NN1: 初始化 JNS

    ./bin/hdfs namenode -initializeSharedEdits
  - nodeX: 停止 journalnode 服务

    ./sbin/hadoop-daemon.sh stop journalnode

知识讲解

集群初始化

- 启动集群
  - NN1: 启动 hdfs

    ./sbin/start-dfs.sh
  - NN1: 启动 yarn

    ./sbin/start-yarn.sh
  - NN2: 启动热备 resourcemanager

    ./sbin/yarn-daemon.sh start resourcemanager

知识讲解

集群验证

- 查看集群状态
  - 获取 namenode 状态

```
./bin/hdfs haadmin -getServiceState nn1
./bin/hdfs haadmin -getServiceState nn2
```

  - 获取 resourcemanager 状态

```
./bin/yarn rmadmin -getServiceState rm1
./bin/yarn rmadmin -getServiceState rm2
```

知识讲解

集群验证

- 查看集群状态
  - 获取节点信息

```
./bin/hdfs  dfsadmin  -report
./bin/yarn   node   -list
```

  - 访问集群文件

```
./bin/hadoop  fs  -mkdir  /input
./bin/hadoop  fs  -ls  hdfs://mycluster/
```

  - 主从切换 acitvate

```
./sbin/hadoop-daemon.sh  stop  namenode
```

知识讲解

Tedu.cn
达内教育

总结答疑